

Veri Kalitesi

Güvenilir Veriyi Nasıl Tanırız?

Veri kalitesi, güvenin ölçülebilir halidir.

Governance oturumuna köprü

$$\text{Güven} = \text{Tanım} + \text{Sahiplik} + \underline{\text{Kalite Sinyali}}$$

Data Governance ile ilk iki ayağı kurduk: tanım ve sahiplik. Şimdi üçüncü ayağı açıyoruz — kalite sinyali.

Tanım 'kime sorarız'ı; kalite sinyali 'neye bakarız'ı söyler.

Bu oturumun altı durağı

Her durak, bir önceki durağın üzerine inşa edilir.

01

Neden Kalite?

Kötü verinin sessiz maliyeti.

02

Kalite Nedir?

Amaca uygunluk — mükemmellik değil.

03

Altı Boyut

Kaliteyi ölçülebilir kılan altı boyut.

04

Veriyi Tanımak

Profiling ve tekrar eden hata desenleri.

05

Beklenti Yönetmek

Kural, issue, sahiplik.

06

Sürdürülebilirlik & Vaka

İzleme, AI köprüsü, mini vaka.

Kötü veri bağırılmaz. Sessizce yanlış karar veririr.

En pahalı veri, hatalı olduğunu fark etmediğiniz veridir — çünkü ona güvenerek karar alırsınız.

Kötü verinin sessiz maliyeti

Güven kaybı

“Bu rapora güvenmiyorum” — herkes kendi Excel'ini açar.

Karar riski

Hatalı sayı → hatalı strateji, yanlış yatırım.

Zaman kaybı

Aynı veriyi her ay elle düzeltmek — sessiz zaman hırsızı.

AI/ML başarısızlığı

Çöp veri → çöp model: yanlış öğrenir, güvenle yanılır.

Hiçbiri alarm çalmaz; hepsi sessizce maliyet biriktirir.

Nerede acıtır?

Aynı kötü veri, farklı yerlerde farklı biçimde yaralar.

BI & Dashboard

Şık ama yanıltıcı grafik. Yönetim yanlış sayıya bakıp karar verir.

Finansal raporlama

Ciro mutabakatı tutmaz; denetimde güven sarsılır.


Kampanya

Eksik/yanlış e-posta → bütçe boşa, müşteri rahatsız.

ML / Model

Bayat ve mükerrer veri → model yanlış öğrenir, sahada patlar.

Neden bir Data & AI Bootcamp'inde?



Hepsinin girdisi veridir. Girdi çürükse çıktı çürür: çöp veri, çöp sonuç.

Kalite,
mükemmellik değildir.
Amaca uygunluktur.

Mükemmel veri diye bir şey yoktur — ve peşine düşmek zaman kaybıdır. Soru: veri, işine yetiyor mu?

Kalite = amaca uygunluk

Veri, kullanılacağı işe yetiyorsa kalitelidir. Mükemmel olması gerekmez.

Kampanya listesi için e-posta kritiktir; doğum tarihi olmasa da olur. Aynı veri, başka iş için tam tersi. Amaç, 'yeterli'yi tanımlar.

Aynı tablo, üç ekip, üç “yeterli”

Pazarlama

- email dolu (kritik)
- liste güncel (kritik)
- doğum tarihi (önemsiz)

Finans

- tutarlar doğru (kritik)
- kaynaklar tutar (kritik)
- email (önemsiz)

Veri Bilimi

- last_login taze (kritik)
- mükerrer yok (kritik)
- şehir yazımı (önemsiz)

Tek tablo, üç farklı 'kaliteli' tanımı. Önce 'ne için' diye sorarsınız.

Her şeyi değil, kritik olanı ölç

%100 peşinde koşma

Tüm alanları kusursuz yapmak hem imkansız hem gereksiz.

Amaca göre seç

Kullanım için kritik 3-5 alanı belirle, önce onları ölç.

Önceliklendir

Kritik alanda %95 hedefi, önemsiz alanda 'takip etme' kararı.

Kalite çalışması bir kaynak yönetimidir: en çok karara dokunan veriye en çok dikkati ayırmalısınız.

Veriye güvenin altı boyutu.

Soyut 'kalite' kelimesini, ölçülebilir altı boyuta çeviriyoruz: biri ölçüldüğünde kalite bir his değil, bir sayı olur.

Altı boyut — tek bakışta

Tamlık

Eksik var mı?

Benzersizlik

Tekrar eden kayıt var mı?

Geçerlilik

Kurala uygun mu?

Tutarlılık

Kaynaklar tutuyor mu?

Güncellik

Yeterince taze mi?

Doğruluk

Gerçeği yansıtıyor mu?

Altısı da bir 'mı?' sorusudur — yani hepsi ölçülebilir. Bir veriye sırayla bu altı soruyu sorun.

Tamlık & Benzersizlik

Tamlık

İş sorusu: Eksik değer var mı?

Örnek: email'in %32'si boş.

Tipik hata: Boş zorunlu alanlar.

Etki: Kampanya ulaşamaz; analiz yanlış çıkar.

Benzersizlik

İş sorusu: Aynı kayıt mükerrer mi?

Örnek: aynı customer_id iki kez.

Tipik hata: Tekrarlayan kayıtlar.

Etki: Sayı şişer; model çift sayar.

Geçerlilik & Tutarlılık

Geçerlilik

İş sorusu: Kurala / formata uygun mu?

Örnek: doğum tarihi 2031; email'de '@' yok.

Tipik hata: İmkansız / kuraldışı değer.

Etki: Hesaplar patlar; filtre yanlış.

Tutarlılık

İş sorusu: Kaynaklar & sürümler tutuyor mu?

Örnek: 'İstanbul'/'istanbul'/'İst'.

Tipik hata: Aynı şey, farklı yazım/sayı.

Etki: Raporlar çelişir; güven gider.

Güncellik & Doğruluk

Güncellik

İş sorusu: Yeterince taze mi?

Örnek: last_login medyanı 8 ay önce.

Tipik hata: Bayat veri 'güncel' sanılır.

Etki: 'Aktif' yanlış; kampanya boşa.

Doğruluk

İş sorusu: Gerçeği yansıtıyor mu?

Örnek: adres formatça doğru ama kişi orada değil.

Tipik hata: Geçerli ama gerçek dışı.

Etki: En zor ölçülen; dış kaynak gerekir.

Sık karışan ikililer

Geçerlilik ≠ Doğruluk

Geçerli: kurala uyar (format/aralık).

Doğru: gerçeği yansıtır.

'@' içeren ama sahibine ait olmayan e-posta: geçerli ama yanlış.

Tamlık ≠ Tutarlılık

Tam: alan dolu.

Tutarlı: her yerde aynı.

Şehir her satırda dolu (tam) ama 'İst/İstanbul' (tutarsız) olabilir.

Etkileşim: 'doğum tarihi 2031' hangi boyut? 'email %32 boş' hangisi? 'CRM 120k / Satış 98k' hangisi?

Kullanmadan önce muayene et.

Tanımadığınız veriye güvenmek, gece yarısı bilmediğiniz bir yolda farsız gitmek gibidir. Önce ışığı yakarız: profiling.

Profiling: verinin sağlık kontrolü

Veriyi kullanmadan önce sorduğumuz temel sorular

Satır sayısı

beklenen hacim?

Boş oranı (null %)

ne kadarı eksik?

Distinct sayısı

kaç farklı değer?

Min / Max

aralık makul mü?

Desen (pattern)

format tutuyor mu?

Mükerrer

tekrar var mı?

Aykırı (outlier)

uç değer var mı?

Dağılım

değerler nasıl yayılmış?

Bir profiling çıktısı — birlikte yorumlayalım

Alan	Bulgu	Sinyal
email	%32 boş	Tamlık
customer_id	160 mükerrer	Benzersizlik
birth_date	maks: 2031	Geçerlilik
city	1.240 farklı yazım	Tutarlılık
last_login_date	medyan: 8 ay önce	Güncellik
total_orders	min: -3	Geçerlilik

Tekrar eden hata desenleri

Eksik veri

Mükerrer kayıt

Geçersiz format

İmkansız değer

Tutarsız yazım

Kaynak uyumsuzluğu

Bayat veri

Schema drift

Volume anomaly


Aykırı (outlier)

İyi analist bu desenleri tanır — yeni veride önce bunları arar.

Beklentiye ölçülebilir kıl.

İş beklentisi → kalite boyutu → kural → sonuç → issue → aksiyon. Kaliteyi sezgiden çıkarıp sisteme alıyoruz.

Beklenti kurala çevirmek



Aynı zincir her kalite sorununa uygulanır. Araç dünyasında bu kurallara 'expectation' da denir.

Kalite kuralı: boyut + ölçüt + eşik

customer_id benzersiz	Benzersizlik	%100
email dolu (kampanya)	Tamlık	≥ %95
birth_date ≤ bugün	Geçerlilik	%100
status ∈ {aktif,pasif,churn}	Geçerlilik	%100
total_orders ≥ 0	Geçerlilik	%100

Issue yönetimi: kim çözer, nasıl kapanır?

Data Owner

kararı verir, önceliklendirir (iş tarafı)

Data Steward

tanımı/kaliteyi izler, kök nedeni kovalar

DQ Analyst

kuralı yazar, ölçer, issue'yu açar

Issue log

Eşik

Öncelik

SLA

Kök neden


Tekrar kontrol

Kalite = hata bulmak değil; sorunu sahibine aktarıp iyileşmeyi göstermektir.

Temizlik bir an; kalite bir alışkanlık.

Tek seferlik temizlik biter; sistem kalır. Ve modern dünyada kalite, doğrudan yapay zekanın güvenilirliğine bağlanır.

Kalite yönetimi döngüsü



Döngü bir kez kurulunca kendiliğinden döner; sizin işiniz onu beslemek, her seferinde sıfırdan kurmak değil.

Scorecard & İzleme

Scorecard

Her boyut için tek bakışta puan: tamlik %93, benzersizlik %100, güncellik %78.

Trend

Bu hafta geçen haftaya göre iyileşiyor mu, kötüleşiyor mu?

Threshold & Alarm

Eşik altına düşünce otomatik haber — siz fark etmeden sistem fark eder.

Ölçülmeyen kalite yönetilemez. İzleme, sorunu siz fark etmeden önce yakalar.

AI/ML güveni veri kalitesine dayanır

Hatalı etiket → model yanlış 'doğru' öğrenir

Mükerrer kayıt → bazı örnekleri çift sayar, yanlış olur

Eksik feature → model kör noktayla karar verir

Tutarsız tanım → eğitim ile gerçek farklı şeyi ölçer

Bayat veri → dünün dünyasını tahmin eder

Model, verdiğiniz veriden öğrenir — çöp veri, kendinden emin yanlış bir modeldir.

Şimdi sıra sizde: e-ticaret verisi.

Bugünün her parçasını gerçek bir veri setinde birleştiriyoruz: profiling, boyutlar, kural, issue, sahiplik.

E-ticaret müşteri verisi

Profil özeti (11 kolon)

email	%32 boş
customer_id	160 mükerrer
phone	%20 geçersiz
birth_date	maks 2031
last_login_date	medyan 8 ay
city	1.240 yazım
status	6 değer (2 boş)
source_system	A ≠ B

- 1 Sorunları kalite boyutuyla eşle.
- 2 Churn modeli için en kritik 3 sorun.
- 3 Kampanya için en kritik 3 sorun.
- 4 İlk yazılacak kalite kuralı.
- 5 Issue sahibi + takip aksiyonu.

İkili/grup · 7–10 dk · cevabı bugünkü kavramlarla gerekçelendir.

Vaka çözümü — anahtar

1 · Boyut eşleme

email→Tamlık · mükerrer→Benzersizlik · 2031/phone/–orders→Geçerlilik · last_login→Güncellik · city/source→Tutarlılık

2 · Churn için 3

last_login (güncellik) · mükerrer (sızıntı/çift sayım) · status boş (etiket gürültüsü)

3 · Kampanya için 3

email (tamlık) · phone (geçerlilik) · city (tutarlılık) — ulaşılabilirlik

4 · İlk kural

customer_id %100 benzersiz — her şeyin temeli; sonra amaca göre email ≥ 95

5 · Sahip + aksiyon

Müşteri verisi Data Owner'a issue; Steward kök neden; SLA ile takip, tekrar ölç

“Bu veri bu iş için yeterince iyi mi?”

Güveni siz ölçersiniz

veriye güvenmeyi varsaymaz; profiling'le ölçer

Sadece sorgu değil

sonucu sunmadan önce boyutları kontrol eder

Büyüyen alan

veri kalitesi, gözlemlenebilirlik, profiling — yükselen roller

Sizi ayıran şey

“bu sayıya neden güveniyorum; sorun varsa sahibi kim?”

KAPANIŞ

Güvenilir Veri. Güvenilir Karar.

Bir veriyi kullanmadan önce ilk hangi soruyu sorarsınız?

Kalite kuralları araç dünyasında

Ana akışta kuralları sade anlattık. Bu kavramların araçlardaki karşılığı vardır — (referans için).

Kavram (bizim dil)	Great Expectations karşılığı
email dolu olmalı	<code>expect_column_values_to_not_be_null</code>
customer_id benzersiz	<code>expect_column_values_to_be_unique</code>
status $\in$ {aktif,pasif,churn}	<code>expect_column_values_to_be_in_set</code>
birth_date $\leq$ bugün	<code>expect_column_values_to_be_between</code>
email format doğru	<code>expect_column_values_to_match_regex</code>

Anahtar terimler

Profiling — veriyi kullanmadan önceki sağlık kontrolü

Tamlık — eksik değer var mı

Benzersizlik — mükerrer kayıt var mı

Geçerlilik — kurala/formata uygun mu

Tutarlılık — kaynaklar/sürümler tutuyor mu

Güncellik — yeterince taze mi

Doğruluk — gerçeği yansıtıyor mu

Kalite kuralı — boyut + ölçüt + eşik

Issue log — sorunların kaydı ve takibi

SLA — çözüm süresi taahhüdü

Scorecard — boyut puanları panosu

Schema drift — kaynak yapısının habersiz değişmesi

Altı boyut + hata deseni — tek bakış

Altı boyut → soru

Tamlık → eksik?

Benzersizlik → mükerrer?

Geçerlilik → kurala uygun?

Tutarlılık → tutuyor?

Güncellik → taze?

Doğruluk → gerçek?

10 hata deseni

- Eksik veri
- Mükerrer kayıt
- Geçersiz format
- İmkânsız değer
- Tutarsız yazım
- Kaynak uyumsuzluğu
- Bayat veri
- Schema drift
- Volume anomaly
- Aykırı (outlier)